



Proyecto 1: *Explorando Datos del Mundo Real con Python*

Objetivo

Cada grupo (2 estudiantes) debe elegir un dataset de Kaggle o Datos Argentina, procesarlo y generar un análisis exploratorio con NumPy, Pandas y visualización de datos.

<https://www.kaggle.com/datasets>

<https://datos.gob.ar/dataset>

Instrucciones del Proyecto

1. Elección del dataset

- Buscar un dataset con al menos **10,000 filas** y **10 variables**.
- El dataset debe ser **tabular** (CSV o similar).
- Ejemplos de categorías:
 - Salud (obesidad, actividad física, enfermedades).
 - Economía (PIB, inflación, salarios).
 - Medio ambiente (calidad del aire, clima, deforestación).
 - Deportes (fútbol, básquet, olimpiadas).
 - Cultura (películas, música, libros).

2. Exploración inicial (Pandas)

- Cargar el dataset con Pandas.
- Mostrar dimensiones, tipos de datos y valores nulos.



- Seleccionar al menos **3 variables numéricas** y **3 categóricas** para analizar.

3. Operaciones con arrays (NumPy)

- Convertir dos o más columnas a **arrays de NumPy**.
- Calcular: media, mediana, desviación estándar, percentiles (implementar una función propia que automatice esta parte del análisis)
- Normalizar o escalar una variable con NumPy.

4. Transformaciones y análisis con Pandas

- Manejar valores faltantes (rellenar o eliminar).
- Agrupar datos por una variable categórica y calcular promedios o conteos.
- Crear al menos **2 nuevas columnas derivadas** (ejemplo: índice, clasificación en rangos, diferencias porcentuales).

5. Visualización de datos

- Gráfico de distribución (histograma o KDE).
- Gráfico comparativo (boxplot, violín o barras).
- Serie temporal o línea de tendencia.
- Gráfico avanzado (heatmap, scatter plot con color/size, etc.).

6. Conclusiones

- Responder **3 preguntas de investigación** que se plantearon sobre los datos.
- Escribir un informe de hallazgos.

Entregable

1. Un **Jupyter Notebook** que contenga:



Universidad
Provincial del Sudoeste
Promoviendo el Desarrollo Armónico de la Región

- El dataset cargado
- Celdas de análisis paso a paso.
- Visualizaciones claras.
- Conclusiones al final de cada visualización o procesamiento de datos.
- Exportar resultados procesados a un nuevo CSV.

El Notebook debe estar bien documentado, con comentarios en el código y explicaciones en celdas de texto.

2. El **dataset (csv)** que usaron para el proyecto.

3. El informe de hallazgos en formato PDF.

Criterios de evaluación

La fecha de entrega del proyecto será el **LUNES 5 DE OCTUBRE** y solo un integrante del grupo debe cargar al moodle el proyecto.

Las **sustentaciones** se harán por grupos los días **MARTES 6 DE OCTUBRE, y MARTES 13 DE OCTUBRE**. Publicaremos en el moodle una lista con los grupos y fechas asignadas.

Criterio	Evaluación
Selección y justificación del dataset	Se evalúa que el dataset cumpla con las condiciones mínimas ($\geq 10,000$ filas, ≥ 10 variables) y que se justifique su elección. Esto demuestra la capacidad de identificar datos reales y relevantes para el análisis.
Exploración inicial con Pandas	Se debe describir el dataset: dimensiones, tipos de datos, valores nulos y estadísticas básicas. La exploración inicial es clave para comprender la calidad de los datos y planear el análisis.



Uso de NumPy para análisis numérico

Se evalúa la conversión de columnas a arrays, el cálculo de estadísticas (media, desviación estándar, percentiles, etc.) y alguna transformación (normalización, estandarización). Esto refleja dominio de operaciones vectorizadas y análisis numérico.

Transformaciones y análisis con Pandas

Incluye limpieza de datos, creación de nuevas columnas derivadas y uso de groupby. Refleja la capacidad de organizar, transformar y enriquecer los datos para obtener información significativa.

Visualización de datos

Se deben generar al menos 4 visualizaciones variadas (distribución, comparación, tendencia y avanzada) con títulos, ejes y leyendas claras. Evaluamos la capacidad de comunicar resultados de manera gráfica y comprensible.

Conclusiones y comunicación de resultados

Se espera un informe que responda preguntas de investigación, que interpreten hallazgos y reconozcan las limitaciones. Evaluamos la capacidad de reflexión crítica y síntesis de resultados.

Claridad, orden y presentación del Notebook

Se valora la organización del notebook, comentarios en el código y explicaciones en texto. Esto refleja profesionalismo y asegura que el trabajo sea reproducible y comprensible.

Sustentación oral y defensa del proyecto

Se evalúa la claridad al explicar lo que se hizo, la capacidad de responder preguntas de los profesores y justificar decisiones tomadas. Refleja comprensión real del trabajo y dominio de los conceptos.

Éxitos!