



Universidad
Provincial del Sudoeste
Promoviendo el Desarrollo Armónico de la Región

PROGRAMACIÓN PYTHON AVANZADA

Proyecto 1:

Explorando Datos del Mundo Real con Python

Análisis exploratorio del catálogo de videojuegos de Steam (1997–2019)

Docentes: Alexandra Trujillo-
Jiménez
Alan Luis Valdivia
Miguel Massiris

Integrantes: Olivera Yohana
Urriola Itziar

Sobre el proyecto:

- **Dataset analizado:** Juegos de la tienda Steam (Fuente: Kaggle)
- **Enlace al dataset original:** <https://www.kaggle.com/datasets/nikdavis/steam-store-games>
- **Repositorio GitHub:** https://github.com/YohaOlivera/Proyecto1_Olivera_Urriola_UPSO-Salliquelo

Introducción

Descripción del contexto y dataset

Este proyecto se centra en el análisis de un dataset que proporciona información detallada sobre el catálogo de juegos disponibles en la tienda digital Steam. La base de datos fue construida a partir de la recopilación de datos mediante las API oficiales de Steam Store y SteamSpy, abarcando publicaciones desde inicios de 1997 hasta mediados de 2019. El archivo original cuenta con un volumen robusto de 27.075 filas y 18 columnas. Las variables recopiladas incluyen métricas comerciales e identificatorias (nombre, fecha de lanzamiento, desarrollador, editor y precio de venta base), especificaciones técnicas (compatibilidad de sistemas operativos y géneros), e indicadores de recepción comunitaria (recuento de reseñas positivas y negativas, cantidad de logros y tiempos promedios de juego registrados por los usuarios).

Justificación de la elección

La selección de este conjunto de datos responde a dos motivos principales. Por un lado, cumple con los requerimientos técnicos y académicos exigidos para el desarrollo de este proyecto. Por otro lado, la temática de los videojuegos representa un pasatiempo compartido, lo cual aportó un valor de interés genuino al proceso de exploración analítica.

Preguntas de investigación

A partir de la comprensión inicial de la estructura de los datos, se plantearon los siguientes interrogantes para guiar el análisis:

1. **¿Qué género de videojuego concentra el mayor porcentaje promedio de reseñas positivas por parte de los usuarios?**
2. **¿Existe una relación directa o correlación lineal entre el precio de un videojuego y el nivel de satisfacción de los jugadores?**
3. **¿En qué período anual se produjo la mayor aceleración histórica en la cantidad de lanzamientos dentro de la plataforma Steam?**

Metodología

Limpieza y transformación de datos (Pandas)

Para adecuar el conjunto de datos a las necesidades del análisis, se utilizó la librería Pandas para ejecutar los siguientes pasos de preprocesamiento:

1. **Tratamiento de valores nulos:** Se identificó que las columnas "Desarrollador" y "Editor" presentaban una cantidad marginal de valores nulos (0,0037% y 0,0517% respectivamente). Dada su nula representatividad estadística, se procedió a eliminar estas filas para garantizar la integridad del análisis.
2. **Creación de nuevas variables:** Se crearon nuevas variables derivadas para facilitar las agrupaciones. Entre ellas, se extrajo el "Género principal" del juego, se separaron las plataformas en variables binarias, y se extrajo el "Año de lanzamiento" a partir de la fecha original convirtiéndola al formato datetime.
3. **Creación de métricas de análisis:** Se estandarizó la moneda convirtiendo el precio original (GBP) a dólares estadounidenses (USD) aplicando una tasa de cambio fija. Además, se generó un "Índice de satisfacción" (y su respectivo porcentaje) calculando la proporción de valoraciones positivas sobre el total de interacciones de los usuarios. Por último, mediante la función `pd.cut`, se segmentó el catálogo en cuatro rangos comerciales: Gratis, Económico, Estándar y Premium.

Análisis descriptivo y numérico (NumPy)

Con el objetivo de explorar la distribución de las variables cuantitativas de forma óptima, se aprovechó las herramientas de vectorización de NumPy:

1. **Función estadística personalizada:** Se codificó una función propia en NumPy para calcular automáticamente la media, mediana, desviación estándar, percentiles (25 y 75), rango intercuartílico (IQR), valores mínimos y máximos de las variables clave (Precio, Valoraciones Positivas y Negativas), aplicando previamente filtros para evadir posibles valores NaN.
2. **Normalización:** Para poder comparar la distribución de precios en una escala estándar, se aplicó un escalado matemático (Min-Max) sobre el vector de "Precio usd", comprimiendo todos los valores al rango continuo [0, 1].

Principales gráficos y hallazgos

Análisis preliminar: Distribución del Precio

Previo a responder las preguntas principales, se analizó la distribución general de los precios mediante un Boxplot y un Histograma.

Se detectó que el mercado está fuertemente sesgado hacia la derecha, lo que implica que la mayoría de los precios son bajos y se concentran a la izquierda del gráfico. (Imagen 1)

Aunque existen valores atípicos de hasta 548 USD, el 99% del catálogo cuesta 100 dólares o menos, concentrándose la inmensa mayoría de los títulos en el rango económico de 0 a 10 dólares. (Imagen 2)




Imagen 1. Histograma - Distribución de precio




Imagen 2. Boxplot - Valores atípicos

Respuesta a la Pregunta 1: Satisfacción por Género de Videojuego

¿Qué género de videojuego concentra el mayor porcentaje promedio de reseñas positivas por parte de los usuarios?




Imagen 3. Gráfico de barras - Satisfacción por Género

A partir del análisis comparativo visualizado en el gráfico de barras, se determina que el género que lidera el nivel de satisfacción en la plataforma es **RPG**, alcanzando un índice promedio de 0.75, escoltado inmediatamente por **Adventure** (0.74). Los datos revelan que los juegos con fuerte componente narrativo y bases de usuarios fidelizadas logran una mejor valoración que aquellos dependientes de modelos masivos como Free to Play (0.67) o Simulation (0.64), los cuales enfrentan mayores exigencias por parte de la comunidad.

Respuesta a la Pregunta 2: Relación entre Precio y Satisfacción

¿Existe una relación directa o correlación lineal entre el precio de un videojuego y el nivel de satisfacción de los jugadores?




Imagen 4. Diagrama de dispersión - Precio-Índice de satisfacción




Imagen 5. Mapa de calor - Matriz de Correlación

Para abordar esta cuestión se utilizaron dos enfoques. Primero, un gráfico de dispersión (Scatter Plot) acotado a los precios estándar de la industria (≤ 60 USD), donde la nube de puntos no mostró una tendencia direccional clara. Segundo, la aplicación estadística de un Mapa de Calor (Heatmap) de correlación de Pearson, el cual arrojó un coeficiente de **0.08** al cruzar el precio con el índice de satisfacción. La combinación de ambos análisis confirma de manera contundente que **no existe una relación lineal directa entre el precio de un videojuego y el nivel de satisfacción de los jugadores**. En Steam, la aceptación es completamente independiente del valor monetario del producto.

Respuesta a la Pregunta 3: Evolución Histórica de Lanzamientos

¿En qué período anual se produjo la mayor aceleración histórica en la cantidad de lanzamientos dentro de la plataforma Steam?




Imagen 6. Línea temporal – Evolución histórica de lanzamientos

El gráfico de tendencia temporal evidencia que la mayor aceleración histórica en la plataforma se produjo en el período comprendido entre los años **2014 y 2018** (destacado en el área sombreada del gráfico). Durante este período de cuatro años, la curva rompió su crecimiento moderado previo para volverse decididamente exponencial. Este salto coincide directamente con la implementación de políticas de distribución abierta por parte de Valve, que democratizó el acceso de los desarrolladores independientes a la tienda global.

Es importante aclarar que, como los datos del dataset corresponden hasta mediados del año 2019, no podemos aseverar nada con respecto a ese período, por tal motivo, remarcamos que la “falsa caída” que se observa en el gráfico es producto de lo antes mencionado.

Limitaciones del estudio

Para garantizar la transparencia y el rigor de este análisis exploratorio, es necesario reconocer las siguientes limitaciones técnicas al conjunto de datos utilizados:

- **Temporalidad:** Los datos recopilados abarcan únicamente el período histórico hasta mediados del año 2019. Por consiguiente, el análisis no refleja el estado actual del mercado ni el impacto masivo que tuvo la pandemia de COVID-19 en la industria gaming.
- **Sesgo de participación:** La métrica de "Índice de satisfacción" está construida sobre reseñas voluntarias de los usuarios. Este sistema tiende a sobrerrepresentar las opiniones extremas (muy positivas o muy negativas), dejando fuera la opinión de la base silenciosa de jugadores.
- **Estimación de ventas imprecisa:** La variable "Propietarios" se expresa en rangos extremadamente amplios (ej. 5.000.000 - 10.000.000), lo que limita la precisión de cualquier cálculo financiero o de ingresos netos.
- **Conversión monetaria estática:** La transformación del precio original de Libras Esterlinas (GBP) a Dólares (USD) se realizó utilizando una tasa de cambio fija para todo el período histórico, sin contemplar la inflación, los ajustes de precios regionales ni los habituales períodos de descuentos (Steam Sales).

Futuros pasos de investigación

A partir de los hallazgos obtenidos y reconociendo las limitaciones de este estudio inicial, proponemos las siguientes líneas de investigación para continuar profundizando en el análisis del mercado de videojuegos:

- **Actualización y cruce de datos:** Sería altamente enriquecedor cruzar este dataset histórico con una extracción de datos actualizada al año corriente para evaluar cómo evolucionaron las tendencias de publicación y satisfacción en el mercado contemporáneo.
- **Cuantificación de la variable Propietarios:** Reemplazar los intervalos categóricos actuales por valores numéricos continuos (mediante el punto medio de cada rango). Esta conversión habilitará cálculos financieros como por ejemplo la estimación de ingresos brutos (Precio usd × Propietarios estimados) y permitirá ponderar el nivel de satisfacción de acuerdo al volumen real de copias vendidas.
- **Tratamiento de las etiquetas SteamSpy:** Tratar y desagregar la columna Etiquetas SteamSpy mediante técnicas de análisis multi etiqueta para descubrir nichos y micro tendencias (como por ejemplo juegos de Zombies, Supervivencia, etc.) que los géneros principales no logran capturar.